

курс «Глубокое обучение»

Векторные представления и решение задач с текстами

Александр Дьяконов

План

Классические способы кодирования / представления слов
word2vec, fasttext, Glove

Первые контекстные представления слов
ELMo, FLAIR

Токенизация
BPE, WordPiece

Модели для текстов
CNN, seq2seq, seq2seq+attention

Способы кодирования / представления слов

- **ONE**

слишком большая размерность, нет хорошей близости

- **counts (сумма ONE соседей)**

более нетривиальная оценка близости с помощью cos

- **представления (embeddings)**

умный алгоритм задания кодировки

Представления слов (word embeddings)

решают проблему «что дать на вход сети»

токен / номер → вектор

способ «засунуть» дискретные объекты в НС

представляют слова так, что похожие слова имеют похожие представления

решается (может решаться) проблема незнакомых слов


имеют небольшую размерность

⇒ сокращают число параметров сети

могут быть получены на большом неразмеченном тексте

трансферное обучение

Вложение слов в непрерывное пространство (embedding)



DL-классика: безконтекстные методы

context-free – не учитывающие контекст
учитывают контекст при обучении представления,
но при использовании это уже фиксированный вектор –
контекст не учитывается

- **word2vec** = предсказания слово $\leftrightarrow$ контекст
- **fasttext** = word2vec + ngrams
- **Glove** = разложение матрицы совместной встречаемости

word2vec – дистрибутивная семантика

Трюк: настраиваем модель, но не для использования в задаче, которой учим (нас интересуют формируемые внутренние представления) принцип трансферного обучения (ex: автокодировщики)

Смысл слова определяется контекстом

Полосатая маленькая ***** мурлычит и пьёт молоко

Весна

Ручьи


Тает

Цветёт

Зеленеет

Прилетают

[Mikolov et al. 2013]

word2vec: два подхода к реализации

CBOW = Continuous Bag of Words (быстрее, окно ~ 5, большие корпуса)

skipgram model (раньше считалось, что лучше, окно ~ 10, небольшие корпуса)

это пример самообучения (self-supervision) – когда разметка автоматическая
можно использовать большие корпуса внешних текстов

word2vec: CBOW

Предсказываем слово по контексту
используется реже, чем следующая реализация

$$P(x_t \mid \text{context}(x_t)) = \text{softmax} \left(V \left(\overset{W}{\sum_{x_i \in \text{context}(x_t)}} \overset{ONE(x_i)}{} \right) \right)$$

выделено то, что будем считать кодировкой

контекст – слово (слова), которое недалеко располагается (в окрестности)

<http://mccormickml.com/2016/04/19/word2vec-tutorial-the-skip-gram-model/>

word2vec: CBOW




Fig. 2. The CBOW model. Word vectors of multiple context words are averaged to get a fixed-length vector as in the hidden layer. Other symbols have the same meanings as in Fig 1.

<https://lilianweng.github.io/lil-log/2017/10/15/learning-word-embedding.html>

word2vec: skip-gram

Предсказываем контекст по слову: слово → слово

Source Text	Training Samples
Thequickbrown fox jumps over the lazy dog. →	(the, quick) (the, brown)
The quick brownfoxjumps over the lazy dog. →	(quick, the) (quick, brown) (quick, fox)
Thequick brown foxjumps over the lazy dog. →	(brown, the) (brown, quick) (brown, fox) (brown, jumps)
Thequickbrown fox jumps over the lazy dog. →	(fox, quick) (fox, brown) (fox, jumps) (fox, over)

word2vec: skip-gram




Fig. 1. The skip-gram model. Both the input vector $\mathbf{x}$ and the output $\mathbf{y}$ are one-hot encoded word representations. The hidden layer is the word embedding of size N .

код слова = строка первой матрицы + столбец второй или строка первой матрицы

<https://lilianweng.github.io/lil-log/2017/10/15/learning-word-embedding.html>

word2vec: есть много тонкостей в обучении

Распространённые фразы – одно слово	White_Spunner_Construction Bad_Habits Toxics_Alliance
Частые слова – реже выбираются при обучении	Например, (quick, the)
«Negative Sampling»	Если logloss $l(z) = \log(1 + \exp(-z))$, то $\sum_{t=1}^T \left[\sum_{c \in C_t} l(s(x_t, x_c)) + \sum_{x \in N_{t,c}} l(-s(x_t, x)) \right] \rightarrow \min$ $s(x_t, x_c) = \text{vec}(x_t)^T \cdot \text{vec}(x_c)$ – тут представление входа и выхода

<http://mccormickml.com/2017/01/11/word2vec-tutorial-part-2-negative-sampling/>

Есть отличия между реализацией и статьёй!

Операции над представлениями слов




Figure 2: Two-dimensional PCA projection of the 1000-dimensional Skip-gram vectors of countries and their capital cities. The figure illustrates ability of the model to automatically organize concepts and learn implicitly the relationships between them, as during the training we did not provide any supervised information about what a capital city means.

[Mikolov et al., 2013] <https://arxiv.org/pdf/1310.4546.pdf>

Другие представления: fasttext

тоже «слово → контекст»

попытка учесть морфологию слов

раньше «сеть», «сетевой», «сетью» разные векторы...

+ использовать n-граммные представления слова

«where» ~ <wh, whe, her, ere, re>

n-граммы хэшируются;

код = сумма кодов для n-грамм


решается проблема новых слов

Bojanowski P. et al. «Enriching Word Vectors with Subword Information» //

<https://arxiv.org/pdf/1607.04606.pdf>

<https://fasttext.cc> – тут есть все ссылки!!!

Glove: Global Vectors for Word Representation



$\#ij$ – сколько раз слово j в контексте слова i
(на расстоянии $\leq k$ слов) есть и другие варианты

$$\sum_{i,j} f(\#ij)(w_i^T \tilde{w}_j + b_i + \tilde{b}_j - \log(\#ij))^2 \rightarrow \min$$

<https://nlp.stanford.edu/projects/glove/>

Glove: ближайшие соседи

frog
frogs
toad
litoria
leptodactylidae
rana
lizard
leutherodactylus



3. litoria




4. leptodactylidae




5. rana




7. eleutherodactylus




man - woman



company - ceo



city - zip code



comparative - superlative

Проверка представлений

1) визуально смотрим проекцию в пространстве, кластеры слов и т.п.

**2) ближайшие соседи
есть бенчмарки схожих слов**

https://nlp.stanford.edu/~lmthang/data/papers/conll13_morpho.pdf

задача «найди лишнее слово»

3) проверка арифметики

«король – мужчина + женщина = королева»

есть бенчмарки аналогий <https://arxiv.org/pdf/1301.3781.pdf>

**кстати, в разных языках одинаковые линейные отношения
это позволяет наложить представление одного языка на другое!**

4) качество при решении задач ML (downstream tasks)

ex: классификация тональности текстов фиксированным классификатором

Проверка представлений

Словарь аналогий

Table 1: *Examples of five types of semantic and nine types of syntactic questions in the Semantic-Syntactic Word Relationship test set.*

Type of relationship	Word Pair 1		Word Pair 2	
Common capital city	Athens	Greece	Oslo	Norway
All capital cities	Astana	Kazakhstan	Harare	Zimbabwe
Currency	Angola	kwanza	Iran	rial
City-in-state	Chicago	Illinois	Stockton	California
Man-Woman	brother	sister	grandson	granddaughter
Adjective to adverb	apparent	apparently	rapid	rapidly
Opposite	possibly	impossibly	ethical	unethical
Comparative	great	greater	tough	tougher
Superlative	easy	easiest	lucky	luckiest
Present Participle	think	thinking	read	reading
Nationality adjective	Switzerland	Swiss	Cambodia	Cambodian
Past tense	walking	walked	swimming	swam
Plural nouns	mouse	mice	dollar	dollars
Plural verbs	work	works	speak	speaks

Семантический сдвиг




Figure 1: Two-dimensional visualization of semantic change in English using SGNS vectors.² a, The word *gay* shifted from meaning “cheerful” or “frolicsome” to referring to homosexuality. b, In the early 20th century *broadcast* referred to “casting out seeds”; with the rise of television and radio its meaning shifted to “transmitting signals”. c, *Awful* underwent a process of pejoration, as it shifted from meaning “full of awe” to meaning “terrible or appalling” (Simpson et al., 1989).

обучаем модель на текстах разных периодов

«выравниваем» пространства линейным/ортогональным преобразованием

логично применять растяжение и поворот

William L. Hamilton, et al. «Diachronic Word Embeddings Reveal Statistical Laws of Semantic Change» // <https://www.aclweb.org/anthology/P16-1141.pdf>

«Наложение языков»


Ingredients:

- corpus in one language (e.g., **English**)
- corpus in another language (e.g., **Spanish**)
- very small dictionary

cat ↔ gato
 cow ↔ vaca
 dog ↔ perro
 fox ↔ zorro
 ...


Step 1:

- train embeddings for each language




Step 2:

- linearly map one embeddings to the other to match words from the dictionary



Step 3:

- after matching the two spaces, get new pairs from the new matches



https://lena-voita.github.io/nlp_course/word_embeddings.html

<https://arxiv.org/pdf/1309.4168.pdf>

Бонус: сексизм в представлениях

есть классические равенства

$$\overrightarrow{\text{man}} - \overrightarrow{\text{woman}} \approx \overrightarrow{\text{king}} - \overrightarrow{\text{queen}}$$

но есть также

$$\overrightarrow{\text{man}} - \overrightarrow{\text{woman}} \approx \overrightarrow{\text{computer programmer}} - \overrightarrow{\text{homemaker}}$$

Extreme <i>she</i> occupations						Extreme <i>he</i> occupations					
1. homemaker	2. nurse	3. receptionist		1. maestro	2. skipper	3. protege					
4. librarian	5. socialite	6. hairdresser		4. philosopher	5. captain	6. architect					
7. nanny	8. bookkeeper	9. stylist		7. financier	8. warrior	9. broadcaster					
10. housekeeper	11. interior designer	12. guidance counselor		10. magician	11. fighter pilot	12. boss					

Figure 1: The most extreme occupations as projected on to the *she*–*he* gender direction on g2vNEWS. Occupations such as *businesswoman*, where gender is suggested by the orthography, were excluded.

Tolga Bolukbasi et al. «Man is to Computer Programmer as Woman is to Homemaker? Debiasing Word Embeddings» // <https://arxiv.org/pdf/1607.06520.pdf>

Контекстные представления слов – Contextualized Word Embeddings

недостатки предыдущих вложений – не учитывают контекст

«Рискую всем банком»

«В банке не работал кондиционер»

«Хранить деньги в банках не стоит»

«На банке сидела муха»

«The bank will not be accepting cash on Saturdays»

«The river overflowed the bank»

Выход:

языковые модели

- embeddings in Tag LM
 - CoVe
 - ELMo
 - Flair

ELMo: Embeddings from Language Models

представление с помощью предтренировки без учителя
biLM обучена на большом корпусе текстов

новое предложение в нашей задаче пропускается через biLM
представление слоя = лк состояний слова

⇒


- **зависит от всего предложения**
- **глубокое (зависит от всех слоёв)**
- **есть возможность его обучать (т.к. лк)**

Matthew E. Peters, Mark Neumann, Mohit Iyyer, Matt Gardner, Christopher Clark, Kenton Lee, Luke Zettlemoyer «Deep contextualized word representations» // <https://arxiv.org/abs/1802.05365>

ELMo: Embeddings from Language Models

$$\sum_k \log p(t_k \mid t_1, \dots, t_{k-1}; \Theta_x, \theta_{\text{LSTM}}^{\rightarrow}, \Theta_s)) + \log p(t_k \mid t_{k+1}, \dots, t_n; \Theta_x, \theta_{\text{LSTM}}^{\leftarrow}, \Theta_s))$$

можно заточивать представление под конкретную задачу –
– такую л/к скрытых состояний



$$\text{ELMO}_k = \gamma^{\text{task}} \sum_{l \in \text{layers}} s_j^{\text{task}} [\vec{h}_{k,j}^{\text{LM}}, \overleftarrow{h}_{k,j}^{\text{LM}}]$$

сюда ещё добавляют и выход embedding-слоя

разные слои – разный уровень абстракции
низкие ~ части речи
высокие ~ ответы на вопросы


ELMo: Embeddings from Language Models

Source		Nearest Neighbors
GloVe	play	playing, game, games, played, players, plays, player, Play, football, multiplayer
biLM	Chico Ruiz made a spectacular <u>play</u> on Alusik 's grounder {...}	Kieffer , the only junior in the group , was commended for his ability to hit in the clutch , as well as his all-round excellent <u>play</u> .
	Olivia De Havilland signed to do a Broadway <u>play</u> for Garson {...}	{...} they were actors who had been handed fat roles in a successful <u>play</u> , and had talent enough to fill the roles competently , with nice understatement .

Table 4: Nearest neighbors to “play” using GloVe and the context embeddings from a biLM.

FLAIR: Contextual String Embeddings for Sequence Labelling

учим посимвольную двунаправленную LM (Character-level Language Model)
конкатенируем скрытое состояние последней буквы LM $\rightarrow$, первой LM $\leftarrow$



Alan Akbik, Duncan Blythe, Roland Vollgraf «Contextual String Embeddings for Sequence Labeling» <https://www.aclweb.org/anthology/C18-1139/>

FLAIR: Contextual String Embeddings for Sequence Labelling

word	context	selected nearest neighbors
Washington	(a) <i>Washington to curb support for [..]</i>	(1) <i>Washington would also take [..] action [..]</i> (2) <i>Russia to clamp down on barter deals [..]</i> (3) <i>Brazil to use hovercrafts for [..]</i>
Washington	(b) <i>[..] Anthony Washington (U.S.) [..]</i>	(1) <i>[..] Carla Sacramento (Portugal) [..]</i> (2) <i>[..] Charles Austin (U.S.) [..]</i> (3) <i>[..] Steve Backley (Britain) [..]</i>
Washington	(c) <i>[..] flown to Washington for [..]</i>	(1) <i>[..] while visiting Washington to [..]</i> (2) <i>[..] journey to New York City and Washington [..]</i> (14) <i>[..] lives in Chicago [..]</i>
Washington	(d) <i>[..] when Washington came charging back [..]</i>	(1) <i>[..] point for victory when Washington found [..]</i> (4) <i>[..] before England struck back with [..]</i> (6) <i>[..] before Ethiopia won the spot kick decider [..]</i>
Washington	(e) <i>[..] said Washington [..]</i>	(1) <i>[..] subdue the never-say-die Washington [..]</i> (4) <i>[..] a private school in Washington [..]</i> (9) <i>[..] said Florida manager John Boles [..]</i>

Table 4: Examples of the word “Washington” in different contexts in the CONLL03 data set, and nearest neighbors using cosine distance over our proposed embeddings. Since our approach produces different embeddings based on context, we retrieve different nearest neighbors for each mention of the same word.


Совместное использование представлений

можно конкатенировать разные представления

использовать одни как инициализации для вычисления других

Представление текстов: сейчас не будем подробно

**умеем представлять (вкладывать) слова
как быть с предложениями / абзацами / текстами?**



<https://amitness.com/2020/06/universal-sentence-encoder/>

Представление текстов: SentenceBERT




Figure 1: SBERT architecture with classification objective function, e.g., for fine-tuning on SNLI dataset. The two BERT networks have tied weights (siamese network structure).




Figure 2: SBERT architecture at inference, for example, to compute similarity scores. This architecture is also used with the regression objective function.

Nils Reimers, Iryna Gurevych «Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks» // <https://arxiv.org/abs/1908.10084>
Библиотека <https://www.sbert.net/>

BERTScore – оценка схожести предложений (чуть-чуть не в тему)








Figure 1: Illustration of the computation of the recall metric R_{BERT} . Given the reference x and candidate $\hat{x}$, we compute BERT embeddings and pairwise cosine similarity. We highlight the greedy matching in red, and include the optional idf importance weighting.

Tianyi Zhang, et al. «BERTScore: Evaluating Text Generation with BERT»
<https://arxiv.org/abs/1904.09675>

Итог по представлениям



<http://tiny.cc/NAACLTransfer>

Токенизация на подслова (Subword Tokenization)

- кто сказал, что подавать текст надо по словам?
 - уже видели объединения слов
«machine learning» → ML_word
- слова состоят из интерпретируемых частей (может, кодировать их?)
«subword» → «sub» + «word»
- так и не решили проблему OOV и такую:
«Yeeees! Gooooood!»
«айфонизация...»

Представление слов

- **токенизация на подслова**

расскажем только про это: BPE, WordPiece

- **посимвольный подход**

сеть обрабатывает символы и выдаёт код всего слова

- **гибридный подход**

если знаем код слова – выдаём, иначе посимвольный подход

**токен – элемент представления текста для сети
(то что для нас слово или буква)**

словарь – множество допустимых токенов

Byte Pair Encoding (BPE)

Обучение BPE

- **Слово = последовательность токенов (пока символов) + специальный символ конца** (изначально использовались unicode-символы)
- **Словарь = все токены (на нулевой итерации – символы)**
- **Повторять пока не достигли ограничения на размер словаря**
 - **Назначаем новым токеном объединение двух существующих токенов, которое встречается чаще других пар в корпусе**

Применение BPE (возможны варианты)

идём по всем токенам по убыванию частоты – находим соответствующую последовательность символов в корпусе, заменяем на токен

Rico Sennrich et al. «Neural Machine Translation of Rare Words with Subword Units» <https://arxiv.org/abs/1508.07909>
ещё есть работа [Philip Gage, 1994] откуда, собственно, термин BPE

Byte Pair Encoding (BPE)

AABABCSABBAABAC

A**DD****C****D****B****A****D****A****C**

E**D****C****D****B****E****A****C**

AA – 2

AB – 4 AB = D

BA – 3

BC – 1

CA – 1

BB – 1

AC – 1

AD – 2 AD = E

DD – 1

DC – 1

CD – 1

DB – 1

DA – 1

AC – 1

На практике

«I_{</w>} like_{</w>} ke_{</w>}» → «I_{</w>}», «li», «##ke_{</w>}», «ke_{</w>}»

- различают токен изолированный и токен внутри слова
 - есть специальный символ конца слова

Algorithm 1 Learn BPE operations

```

import re, collections

def get_stats(vocab):
    pairs = collections.defaultdict(int)
    for word, freq in vocab.items():
        symbols = word.split()
        for i in range(len(symbols)-1):
            pairs[symbols[i],symbols[i+1]] += freq
    return pairs

def merge_vocab(pair, v_in):
    v_out = {}
    bigram = re.escape(' '.join(pair))
    p = re.compile(r'(?!\S)' + bigram + r'(?!\S)')
    for word in v_in:
        w_out = p.sub(' '.join(pair), word)
        v_out[w_out] = v_in[word]
    return v_out

vocab = {'l o w </w>' : 5, 'l o w e r </w>' : 2,
        'n e w e s t </w>':6, 'w i d e s t </w>':3}
num_merges = 10
for i in range(num_merges):
    pairs = get_stats(vocab)
    best = max(pairs, key=pairs.get)
    vocab = merge_vocab(best, vocab)
    print(best)

```

r·	→	r·
l o	→	l o
l o w	→	l o w
e r·	→	e r·

Figure 1: BPE merge operations learned from dictionary {‘low’, ‘lowest’, ‘newer’, ‘wider’}.

BPE в GPT2

- **вход – последовательность байтов (а не юникод-символов)**
- **не сливают символы разного типа (e.g. буквы и знаки пунктуации)**

«dog», «dog!», «dog?»

Иллюстрация токенизации

Large generative models (e.g., large language models, diffusion models) have shown remarkable performance, but they require a massive amount of computational resources. To make them more accessible, it is crucial to improve their efficiency. This course will introduce efficient AI computing techniques that enable powerful deep learning applications on resource-constrained devices. Topics include model compression, pruning, quantization, neural architecture search, distributed training, data/model parallelism, gradient compression, and on-device fine-tuning. It also introduces application-specific acceleration techniques for large language models, diffusion models, video recognition, and point cloud. This course will also cover topics about quantum machine learning. Students will get hands-on experience deploying large language models (e.g., LLaMA 2) on a laptop.

110 слов → 162 токена

<https://platform.openai.com/tokenizer>

WordPiece

WordPiece – это BPE, но при объединении максимизируем правдоподобие, а не частоту
В BERT был реализован WordPiece, но в RoBERTa показали, что использование BPE
особо ничего не меняет

If my understanding is correct, this means that aside from just the bigram frequency, the frequency of the original symbols that constitute the bigram are also taken into account. The log likelihood of a sentence in a unigram language model (assuming independence between the words in a sentence) is simply the sum of the log frequencies of its constituent symbols. This means merging two symbols will increase the total log likelihood by the log likelihood of the *merged* symbol and decrease it by the log likelihood of the two *original* symbols. Assuming we merge symbols x and y , the increase in the log likelihood is

$$\log p(x, y) - \log p(x) - \log p(y) = \log \frac{\log(p(x))}{\log(p(x))\log(p(y))}$$

Schuster, Nakajima «Japanese and Korea voice search», 2012

<https://static.googleusercontent.com/media/research.google.com/ja//pubs/archive/37842.pdf>

BPE-Dropout

- у BPE каждое слово имеет однозначную сегментацию
- подслова редких слов не очень интерпретируемы

Ivan Provilkov, Dmitrii Emelianenko, Elena Voita «BPE-Dropout: Simple and Effective Subword Regularization» // <https://arxiv.org/pdf/1910.13267.pdf>

BPE-Dropout




Figure 1: Segmentation process of the word ‘unrelated’ using (a) BPE, (b) *BPE-dropout*. Hyphens indicate possible merges (merges which are present in the merge table); merges performed at each iteration are shown in green, dropped – in red.

BPE-Dropout использует словарь и таблицу слияний BPE, но на каждом шаге слияния случайно его пропускает («дропает»)

p=0 ⇒ BPE
p=1 ⇒ сегментация по буквам

BPE-Dropout

Algorithm 1: BPE-dropout

```

current_split  $\leftarrow$  characters from input_word;
do
    merges  $\leftarrow$  all possible merges of tokens
        from current_split;
    for merge from merges do
        /* The only difference
           from BPE */
        remove merge from merges with the
            probability p;
    end
    if merges is not empty then
        merge  $\leftarrow$  select the merge with the
            highest priority from merges;
        apply merge to current_split;
    end
while merges is not empty;
return current_split;

```

	BPE	Kudo (2018)	BPE-dropout
IWSLT15			
En-Vi	31.78	32.43	33.27
Vi-En	30.83	32.36	32.99
En-Zh	21.07	23.15	23.27
Zh-En	18.29	21.10	21.45
IWSLT17			
En-Fr	39.37	39.45	40.02
Fr-En	38.18	38.88	39.39
En-Ar	13.89	14.43	15.05
Ar-En	31.90	32.80	33.72
WMT14			
En-De	27.41	27.82	28.01
De-En	32.69	33.65	34.19
ASPEC			
En-Ja	43.69	44.92	44.19
Ja-En	30.77	31.23	31.29

Table 2: BLEU scores. Bold indicates the best score and all scores whose difference from the best is not statistically significant (with p -value of 0.05). (Statistical significance is computed via bootstrapping (Koehn, 2004).)

BPE-Dropout

	BPE	BPE-dropout		
		src-only	dst-only	both
250k	26.94	27.98	27.71	28.40
500k	29.28	30.12	29.40	29.89
1m	30.53	31.09	30.62	31.23
4m	33.38	33.89	33.46	33.85

Table 3: BLEU scores for models trained with *BPE-dropout* on a single side of a translation pair or on both sides. Models trained on random subsets of WMT14 En-Fr dataset. Bold indicates the best score and all scores whose difference from the best is not statistically significant (with *p*-value of 0.05).




Figure 2: BLEU scores for the models trained with *BPE-dropout* with different values of *p*. WMT14 En-Fr, 500k sentence pairs.




Figure 3: BLEU scores. Models trained on random subsets of WMT14 En-Fr.

withdra		resul		meeting		olec		comptroll	
BPE	BPE-dropout	BPE	BPE-dropout	BPE	BPE-dropout	BPE	BPE-dropout	BPE	BPE-dropout
aimed	withd	undert	result	meetings	meetings	olecular	molec	icial	comptrollership
molecules	withdrawal	checkl	results	meet	meet	molecules	olecular	supervis	comptroller
aromatic	withdraw	maastr	resulting	session	eting	ljubl	molecule	&	troll
specialties	withdrawn	&	resulted	conference	me	zona	molecular	subcomm	controll
publishers	withdrew	unisp	ults	met	etings	choler	molecules	yugosl	contoller
chain	withdrawals	phili	res	workshop	met	oler	aec	trigg	controlled
americ	withdrawing	ζ	resultant	meets	meets	ospheric	oler	sophistic	controllers
chron	dra	preca	ult	sessions	session	olar	tolu	obstac	control
eager	retire	prosecut	ul	convened	et	elic	omet	reag	contro
ighty	reti	tali	outcome	reunion	conference	ochlor	olip	entals	controls

Figure 5: Examples of nearest neighbours in the source embedding space of models trained with BPE and *BPE-dropout* Models trained on WMT14 En-Fr (4m).

качество лучше на вложениях (embeddings)

Решение задач с текстами: CNN





Figure 1: Model architecture with two channels for an example sentence.

два входных канала, т.к. были и эксперименты, когда один канал обучался...

Yoon Kim «Convolutional Neural Networks for Sentence Classification» //

<https://arxiv.org/abs/1408.5882>

Решение задач с текстами: seq2seq



<http://www.davidsbatista.net/blog/2020/01/25/Attention-seq2seq/>

Sutskever I. «Sequence to Sequence Learning with Neural Networks», 2014 // <https://arxiv.org/abs/1409.3215>

Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation

Kyunghyun Cho et. al. «Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine

Translation» <https://www.aclweb.org/anthology/D14-1179/>

Модель seq2seq: как переводить последовательность → последовательность

Многослойная (4 слоя) LSTM

размерность представления = 1000

входной словарь = 160,000

выходной словарь = 80,000

кодировщик (encoder) – декодировщик (decoder)

кодировщик: входная последовательность → вектор

декодировщик: вектор → целевая последовательность

Это разные LSTM, у них разные параметры!

Интересно: в задаче перевода качество повышалось


инвертирование порядка входа!

Обучение 10 дней

Тоже хороши ансамбли

Модель seq2seq

здесь декодировщик называют также **языковой моделью**



при работе (inference) – подаём на вход сгенерированное
при обучении – среднее ошибок на всех выходах

тонкости:

на рисунке в декодировщике передаётся только его внутреннее состояние
выход кодировщика передаётся лишь первому элементу
можно его передавать всем – чтобы информация о входе была у всех

Модель seq2seq: внутреннее представление предложений





Figure 2: The figure shows a 2-dimensional PCA projection of the LSTM hidden states that are obtained after processing the phrases in the figures. The phrases are clustered by meaning, which in these examples is primarily a function of word order, which would be difficult to capture with a bag-of-words model. Notice that both clusters have similar internal structure.


left-to-right beam-search decode **потом будет**
если выбираем лучшего следующего, не обязательно максимизируем качество

Обобщения seq2seq

В одном векторе вся информация о тексте... плохо
(особенно для длинных последовательностей)



Решение – механизм внимания




Bahdanau et al. 2015 «Neural Machine Translation by Jointly Learning to Align and Translate»

// ICLR 2015 <https://arxiv.org/pdf/1409.0473.pdf>

Механизм внимания

Концепция: есть взаимосвязи между словами



**кодировщик передаёт в декодировщик не только одно состояние,
а состояния всех токенов!**

– но для этого нужен механизм пулинга посл-ти состояний любой длины
выход – пулинг по схожести

<https://lilianweng.github.io/lil-log/2018/06/24/attention-attention.html#born-for-translation>

Механизм внимания




Figure 1: The graphical illustration of the proposed model trying to generate the t -th target word y_t given a source sentence $(x_1, x_2, \dots, x_T)$.

Не кодируем всё предложение одним вектором!

Добавляется контекстный вектор (конкатенируется)

$$c_t = \sum_{j=1}^T \alpha_{tj} h_j$$

веса (softmax)

$$\alpha_{tj} = \frac{\exp(e_{tj})}{\sum_{k=1}^T \exp(e_{tk})}$$

Насколько соответствуют состояния

$$e_{tj} = a(s_{t-1}, h_j)$$

Bidirectional RNN (BiRNN) $\Rightarrow$

учитываются не только слова ДО, но и ПОСЛЕ

Конкатенация состояния ДО и состояния ПОСЛЕ

Механизм внимания

соответствие $e_{tj} = a(s_{t-1}, h_j)$ может быть:

Basic dot-product https://arxiv.org/pdf/1508.04025.pdf	$a(s, h) = s^T h$
Multiplicative attention https://arxiv.org/pdf/1508.04025.pdf	$a(s, h) = s^T W h$
Additive attention https://arxiv.org/pdf/1409.0473.pdf	$a(s, h) = w^T \tanh(W_1 s - W_2 h) = w^T \tanh(W[s; h])$
Scaled dot-product http://papers.nips.cc/paper/7181-attention-is-all-you-need.pdf	$a(s, h) = s^T h / \sqrt{d}$
Content-base attention https://arxiv.org/abs/1410.5401	$a(s, h) = \cos(s, h)$


+ разные нормировки по размерности

Thang Luong, Hieu Pham, Christopher D. Manning «Effective Approaches to Attention-based Neural Machine Translation» <https://www.aclweb.org/anthology/D15-1166.pdf>

Механизм внимания

Encoding Stage

Attention Decoding Stage



полученный в л/к состояний кодировщика вектор конкатенируем с текущим состоянием

Механизм внимания: получаем интерпретацию и выравнивание (alignment)




Figure 3: Four sample alignments found by RNNsearch-50. The x-axis and y-axis of each plot correspond to the words in the source sentence (English) and the generated translation (French), respectively. Each pixel shows the weight α_{ij} of the annotation of the j -th source word for the i -th target word (see Eq. (6)), in grayscale (0: black, 1: white). (a) an arbitrary sentence. (b–d) three randomly selected samples among the sentences without any unknown words and of length between 10 and 20 words from the test set.

Бабданов Д. и др. «Neural Machine Translation by Jointly Learning to Align and Translate» // <https://arxiv.org/abs/1409.0473>

Механизм внимания: решение проблемы «узкого горла»





Figure 2: The BLEU scores of the generated translations on the test set with respect to the lengths of the sentences. The results are on the full test set which includes sentences having unknown words to the models.

seq2seq vs attention



Внимание – техника вычисления взвешенной суммы значений (values) по запросу (query)
~ техника получения описания (representation) фиксированного размера по запросу

<https://zhuanlan.zhihu.com/p/37290775>

Плюсы механизма внимания (Attention)


- улучшает качество перевода (и не только)
- решает проблему «узкого горла»
- появляется интерпретируемость
- решает проблему «затухания сигнала» / исчезающего градиента
- получаем выравнивание (alignment) «бесплатно» в переводе

Виды внимания

Self-Attention / intra-attention	к разным позициям одной и той же входной последовательности
Global / Soft	ко всему входу
Local / Hard	к части входа

<http://proceedings.mlr.press/v37/xuc15.pdf>


Виды внимания: Global vs Local Attention




<https://lilianweng.github.io/lil-log/2018/06/24/attention-attention.html#born-for-translation>

Виды внимания


Convolution




Global attention



Fully Connected layer



Local attention



<https://theaisummer.com/attention/>

Итог

Есть классические способы представления

Лучше учитывать контекст

Сейчас стандарт – токенизация

Можно получать представления целых предложений / текстов

Важно дальше: представления можно обучать вместе с моделью

свёрточные сети – не только для изображений (можно и CNN + RNN)

seq2seq – простая и понятная архитектура

механизм внимания – способ заглянуть в состояния кодировщика

Есть разные виды внимания

Ссылки

хорошо тонкости методов расписаны

<https://lilianweng.github.io/lil-log/2017/10/15/learning-word-embedding.html>

хороший обзор по этой теме

https://lena-voita.github.io/nlp_course/

хороший tutorial по w2v

<http://mccormickml.com/2017/01/11/word2vec-tutorial-part-2-negative-sampling/>

коллекция старых представлений

<https://github.com/Separius/awesome-sentence-embedding>

Обзор про внимание

<https://lilianweng.github.io/lil-log/2018/06/24/attention-attention.html>